

# Analisi di robustezza di uno studio sull'allineamento cognitivo

Bigon Marco, Fabris Luca, Pivato Loris, Romanato Gaia

## Indice

|          |                                                                                                               |           |
|----------|---------------------------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduzione</b>                                                                                           | <b>2</b>  |
| 1.1      | Studio originale: Conceptual alignment in a joint picture-naming task performed with a social robot . . . . . | 2         |
| 1.2      | Linguistic alignment with an artificial agent: A commentary and re-analysis                                   | 3         |
| <b>2</b> | <b>Metodi</b>                                                                                                 | <b>6</b>  |
| 2.1      | Obiettivi e ipotesi di ricerca . . . . .                                                                      | 6         |
| 2.2      | Scelte di multiverse . . . . .                                                                                | 7         |
| <b>3</b> | <b>Risultati</b>                                                                                              | <b>9</b>  |
| 3.1      | Specification curve . . . . .                                                                                 | 9         |
| 3.2      | Volcano plot . . . . .                                                                                        | 13        |
| <b>4</b> | <b>Conclusioni e note metodologiche</b>                                                                       | <b>16</b> |

# 1 Introduzione

## 1.1 Studio originale: Conceptual alignment in a joint picture-naming task performed with a social robot

Cirillo et al. (2022) [1] offrono uno studio sul *Conceptual Alignment*, il processo cognitivo che porta due individui in comunicazione tra loro ad *allinearsi concettualmente*, cioè ad influenzarsi a vicenda nell'utilizzare termini, stili lessicali e strutture sintattiche più comuni all'uno o all'altro.

Per studiare la natura di tale *alignment* propongono un esperimento in cui un robot umanoide, visualizzata un'immagine, ne dichiara il nome o la categoria generale a cui appartiene; subito dopo, al partecipante è fornita un'immagine differente di cui dovrà dichiarare il nome (senza ulteriori istruzioni riguardo la specificità).

Tale processo è ripetuto per 225 trial, ad ognuno dei quali viene registrato il tipo di risposta del partecipante (se si riferisce all'oggetto mostrato attraverso il suo nome basilare o alla categoria a cui appartiene). Viene utilizzato un dataset di 450 immagini, di cui 225 sono mostrate al robot e 225 al partecipante (assegnate in modo casuale senza essere ripetute), suddivise in 15 categorie da 30 immagini ciascuna.

Per ogni partecipante, vengono assegnate al robot 10 categorie casuali per cui nominerà sempre l'immagine con il suo nome basilare, mentre per le 5 rimanenti dichiarerà sempre la categoria. Delle 450 immagini, 377 provengono da un dataset preesistente - *MultiPic*, Duñabeitia et al., 2018 [2] - mentre le restanti 73 immagini dette *Novel* sono state create ad-hoc in modo da avere un numero pari di immagini per categoria.

L'obiettivo dell'esperimento è di valutare quando la risposta dell'individuo è allineata con il tipo di risposta del robot, e a quali fattori tale risposta può essere dovuta. Per studiare tale processo Cirillo et al. propongono il seguente Modello Lineare Generalizzato ad Effetti Misti:

$$\text{CATEGORY\_RESPONSE} \sim \text{BLOCK\_4} * \text{CONDITION} + (1|\text{ID}) + (1|\text{ITEM})$$

in cui **CATEGORY\_RESPONSE** indica se il partecipante abbia risposto con un nome base o con la categoria, **BLOCK\_4** indica il raggruppamento dell'ordine dei trial, suddiviso in quattro gruppi ordinati di osservazioni (Il gruppo 1 corrisponde alle prime 56 ~ 57 osservazioni, il gruppo 2 alle 56 ~ 57 osservazioni successive e così via), **CONDITION** indica se nella specifica osservazione il robot abbia espresso il nome dell'immagine (*Basic condition*) o la sua categoria (*Category condition*).

Si osserva che i raggruppamenti di **BLOCK\_4** sono messi a contrasto con il metodo Helmert, cioè ogni blocco è confrontato con la media dei blocchi che lo precedono. Nel modello **BLOCK\_4** e **CONDITION** sono messe in interazione. Al modello è quindi aggiunto un effetto casuale sul partecipante e sull'immagine mostrata.

Dai risultati del modello si osserva che le covariate statisticamente significative sono l'appartenenza del trial al quarto blocco e la condizione di espressione del Robot (ma non la loro interazione).

Cirillo et al. osservano in primis la grande quantità di risposte di tipo *Basic* da parte dei partecipanti, e di come quando il robot dichiara la categoria dell'immagine l'individuo genererà più frequentemente la categoria dell'immagine mostratagli rispetto a quando il robot dichiara il nome proprio dell'oggetto. Concludono quindi che il *Conceptual Alignment* sia generalmente osservabile.

In quanto tale differenza è osservabile sin dal primo blocco, l'articolo sostiene che l'*alignment* osservato sia *automatico*, cioè che l'adattamento inconscio del partecipante con il suo interlocutore avvenga in modo pressoché immediato; notando un ulteriore incremento delle risposte di tipo categoriale nel quarto blocco, suggeriscono la possibilità di un allineamento più deliberato da parte dell'individuo, conscio della strategia di nominazione del robot.

Viene invece negata la possibilità di un allineamento provocato da particolari scelte intenzionali del partecipante, come il nominare la categoria quando non conosce il nome dell'oggetto ritratto, in quanto nel quarto blocco la percentuale di errori di tipo semantico è ridotta (in corrispondenza invece di un aumento della percentuale di risposte di tipo categoriale).

## 1.2 Linguistic alignment with an artificial agent: A commentary and re-analysis

Gastaldon & Calignano [3] pubblicano un articolo che va ad analizzare le scelte intraprese nello studio di Cirillo et al. e, ove necessario, a contestare la validità delle conclusioni tratte. Viene in particolare messa in dubbio la conclusione originale per cui l'*alignment* sarebbe un processo cognitivo dall'effetto pressoché istantaneo (trattandosi quindi di un processo automatico): viene contestata la scelta originale di misurare l'*alignment* attraverso la proporzione di risposte allineate, in quanto sostengono che nonostante sia una misura comune per misurare l'*alignment* nella letteratura, permetterebbe solo di catturare performance trends dei partecipanti e non di valutare direttamente la sua natura, sia essa automatica o strategica.

Per verificare le conclusioni dell'articolo originale viene spostata l'attenzione dal tipo di risposta del partecipante ai suoi *tempi di reazione* nel darla, ipotizzando che la natura di tale variabile sia più affine a quella del costrutto di interesse, permettendo di trarre conclusioni - in teoria - più attendibili. Vengono perciò formulati quattro modelli paralleli (secondo un approccio *multiverse*) che utilizzano i tempi di risposta, misurati in millisecondi, come variabile risposta rispetto alla seguente interazione

$$\text{REACTION\_TIME} \sim \text{BLOCK\_4} * \text{CONDITION} * \text{ALIGNMENT}$$

dove BLOCK\_4 e CONDITION riprendono le definizioni date nell'articolo di Cirillo et al. (per BLOCK\_4 sono mantenuti i contrasti Helmert), mentre ALIGNMENT è una variabile costruita ad-hoc da Gastaldon & Calignano che indica se la risposta del partecipante corrisponda (sia allineata) o meno al tipo di risposta dato dal robot.

Nell'articolo sono presi in esame gli effetti marginali di alcune interazioni sui tempi di reazione:

- Nell'interazione tra BLOCK\_4 e ALIGNMENT si osserva nei primi tre blocchi di trial una divergenza graduale tra i tempi di reazione a risposte allineate (stabili nel tempo) e quelli a risposte non allineate (crescenti); nel quarto (e ultimo) blocco di trial la differenza tra i tempi di risposta è invece nettamente ridotta.
- Nell'interazione tra BLOCK\_4 e CONDITION risulta che quando il robot pronuncia la categoria dell'immagine, i tempi di reazione decrescono per i primi tre blocchi, mentre aumentano nuovamente al quarto. Al contrario, quando il robot usa il nome base i tempi di reazione rimangono stabili nei primi tre blocchi per poi decrescere nettamente nel quarto.
- Nell'interazione tra CONDITION e ALIGNMENT si osserva il comportamento più interessante: quando il partecipante è allineato al robot in condizione *basic* (risponde al nome base con un nome base) i tempi di reazione sono nettamente più rapidi rispetto a quando è allineato alla categoria. In generale, risulta comunque che utilizzare nomi base richieda tempi di reazione più brevi della categoria a prescindere dall'allineamento con il robot.

Oltre a queste osservazioni l'articolo presenta ulteriori analisi descrittive dei dati a disposizione. In particolare viene analizzata la frequenza lessicale nel linguaggio comune di ogni parola presentata ai partecipanti, e come essa modifichi i tempi di reazione. Dall'analisi emerge infatti che i due set di immagini che compongono l'insieme fornito ai partecipanti (*MultiPic* e *Novel*) presentano differenze nella frequenza lessicale media dei soggetti raffigurati: nell'insieme completo si possono osservare forti differenze di frequenza lessicale in diverse categorie (*strumenti musicali* e *frutti* con frequenza ridotta, *edifici* e *parti del corpo* con frequenza maggiore), mentre prendendo in esame il solo dataset *MultiPic* l'unica categoria in cui i soggetti raffigurati hanno una frequenza lessicale differente (maggiore) è quella delle *parti del corpo*.

Viene osservato che quando la condizione del robot è *category* e il partecipante risponde anch'esso con una categoria, metà delle risposte è concentrata in sole due categorie, *frutti* e *strumenti musicali*, con *parti del corpo* come terza categoria più comune; quando invece il partecipante risponde con una categoria alla condizione *basic* del robot (non è allineato), la percentuale di risposte appartenenti alle categorie *frutti* e *strumenti musicali* aumenta ancora di più, mentre il numero di risposte categoriali per *parti del corpo* scende a zero. Viene quindi ipotizzato che il modo in cui il dataset di immagini

è composto porti a una disomogeneità non trascurabile, in quanto appare che per le categorie dalla frequenza lessicale inferiore il non-allineamento rispetto alla condizione *basic* sia più frequente, mentre per quelle dalla frequenza lessicale maggiore tale non-allineamento sia osservato meno di frequente. Emerge inoltre che *frutti* e *strumenti musicali* dominano la percentuale di risposte categoriali date in generale: viene perciò ipotizzato che tale sproporzione influisca sui risultati generali dei modelli di Cirillo et al.

Gastaldon & Calignano verificano quanto le singole categorie impattino sul risultato attraverso un test di robustezza: definito lo stesso modello lineare dell'analisi di Cirillo et al. ( $\text{CATEGORY\_RESPONSE} \sim \text{BLOCK\_4} * \text{CONDITION}$ ), esso viene stimato ripetutamente attraverso una tecnica di *leave-one-out* sulle singole categorie, cioè ad ogni stima del modello tutte le osservazioni in cui viene mostrata un'immagine appartenente ad una certa categoria sono escluse, e sono registrati i valori dei test riguardo il parametro *CONDITION* in assenza della categoria. Questo processo viene fatto due volte, prima aggiungendo al modello un'intercetta casuale per i partecipanti e per le singole immagini mostrate, poi inserendo la sola intercetta per le singole immagini a cui è aggiunta una pendenza casuale per la condizione sui partecipanti.

Nel primo modello, seppur *CONDITION* risulti ancora significativa, si nota una deviazione ed incremento netto del p-value all'esclusione delle parti del corpo e degli strumenti musicali. Nel secondo modello invece, mentre all'esclusione di *strumenti musicali* *CONDITION* rimane ancora a malapena significativa, con l'esclusione di parti del corpo e frutti *CONDITION* perde totalmente significatività, e il segno del coefficiente non è più sempre positivo. Notando che le categorie dall'effetto maggiore corrispondono con quelle dalla frequenza lessicale alterata maggiormente dalla presenza delle immagini *Novel*, viene ipotizzato che tali categorie influenzino particolarmente gli effetti notati nell'articolo originale, e che perciò potrebbe non trattarsi di un fenomeno globale ma circoscritto ad esse (e forse dipendente dal comportamento di alcuni partecipanti, o dalla natura delle immagini stesse come visto dalla differenza tra immagini *MultiPic* e *Novel* o dalla maggiore presenza di errori visivi nella categoria *parti del corpo*).

In base a tutte queste analisi e considerazioni, Gastaldon & Calignano considerano l'effetto di nominazione di categorie particolarmente dipendente dal partecipante e dall'immagine in esame, criticando anche la natura di certe categorie scelte, come le *parti del corpo* e le *professioni* (in quanto ambigue, o dagli elementi troppo specifici o mal specificati). Non contestano la presenza di un *alignment*, ma suggeriscono che quello individuato da Cirillo et al. sia *lessicale* e non *concettuale* come altrimenti dichiarato. Inoltre, affermano che dall'analisi dei tempi di reazione, elemento comune di studio di processi cognitivi automatici, sia suggerito invece un approccio impegnativo e volontario, forse strategico, invece di un processo automatico. Viene però osservato che a prescindere dalla sua natura, tale allineamento potrebbe essere provocato da caratteristiche, comportamenti e strategie personali dell'individuo, o dalla natura delle immagini e delle categorie utilizzate. Serve quindi prudenza nel generalizzare i risultati osservati.

## 2 Metodi

### 2.1 Obiettivi e ipotesi di ricerca

Nel loro studio Cirillo et al. indagano l'allineamento concettuale tra uomo e robot analizzando la proporzione di risposte allineate per la categoria sovraordinata concludono a favore dell'esistenza di un effetto di allineamento che potrebbe essere anche automatico. Conclusione che però Gastaldon & Calignano contestano proponendo di analizzare invece i tempi di risposta come parametro cognitivo più sensibile e accurato per discriminare se un comportamento sia automatico o guidato da uno sforzo strategico, che risultano essere sensibilmente più lunghi e con una maggiore variabilità quando i partecipanti si allineano al robot producendo la categoria sovraordinata, indicando un processo di allineamento strategico e sollevando dubbi sulla reale generalizzabilità dell'effetto a tutte le categorie e a tutti i partecipanti.

Riallacciandosi a quanto emerso dal dibattito teorico tra Cirillo et al. e il commento di Gastaldon & Calignano, l'obiettivo della nostra analisi è verificare se il processo di allineamento linguistico sia di natura automatica o strategica, valutando al contempo la robustezza di tali conclusioni rispetto a diverse scelte di preprocessing, modellazione e inclusione di categorie lessicali.

Il costrutto di interesse è l'allineamento cognitivo a livello concettuale. Operazionalizziamo l'allineamento comportamentale come la produzione, da parte del partecipante umano, dello stesso livello semantico (nome di base o categoria sovraordinata) utilizzato dal robot per una specifica categoria di oggetti. Da un punto di vista teorico, definiamo un allineamento genuinamente “concettuale” come un processo cognitivo automatico e non coscientemente volontario.

Per discriminare se l'allineamento rilevato nell'esperimento abbia carattere automatico o strategico, la definizione operativa della misura si basa sui tempi di reazione dei partecipanti, in quanto rappresentano un indicatore sensibile del carico cognitivo: processi automatici sono tipicamente associati a risposte rapide e stabili, mentre processi strategici o di compensazione generano risposte più lente e una maggiore variabilità dovuta allo sforzo decisionale.

Per testare queste ipotesi, oltre all'inclusione di una struttura di effetti casuali volta a controllare la variabilità non campionaria, i modelli stimati prevedono tre predittori principali: **ALIGNMENT** (risposta allineata vs non allineata), **CONDITION** (livello semantico atteso: nome di base vs categoria sovraordinata) e **ORDER** (l'indice numerico del trial, indicatore della progressione temporale dell'esperimento). Gli effetti di interesse primari e le relative interpretazioni cognitive sono così strutturati:

- **Effetto di ORDER:** Un effetto negativo significativo (diminuzione dei tempi di risposta al crescere dei trial) indicherebbe un mero effetto di apprendimento motorio o di pratica generalizzata nel compito.

- Interazione **ALIGNMENT:CONDITION**: Rappresenta il fulcro del dibattito. Se l'allineamento alla categoria sovraordinata (es. dire “frutto” anziché “mela”) fosse automatico, l'interazione non dovrebbe mostrare rallentamenti significativi rispetto alla condizione di base. Al contrario, se questa interazione risultasse positivamente significativa, indicando tempi di risposta nettamente maggiori quando i partecipanti si allineano in corrispondenza della categoria sovraordinata, verrebbe supportata l'ipotesi di un allineamento strategico e conscio, guidato da un maggiore carico di lavoro mentale.
- Interazione con la componente temporale **order:alignment**: Permette di valutare la dinamica temporale del processo. Un'interazione significativa indicherebbe se lo sforzo cognitivo (strategico) o la facilitazione (automatica) cambiano o si stabilizzano con il procedere dell'esperimento; in particolare, se questa interazione mostrasse un effetto significativo per cui, nel caso di risposte allineate, i tempi di reazione diminuissero più rapidamente al procedere dei trial, questo potrebbe far propendere per un processo di allineamento automatico, il quale facilita la risposta proprio nei casi in cui il partecipante si sintonizza con il robot.

## 2.2 Scelte di multiverse

Per non vincolare queste conclusioni psicologiche a una singola e arbitraria catena di decisioni analitiche, abbiamo deciso di adottare un approccio di analisi del multiverso, esplorando sistematicamente lo spazio di tutte le combinazioni di preprocessing e modellazione statisticamente difendibili. Le scelte di multiverse effettuate sono state:

1. **Filtro sulle immagini da includere** (2 diramazioni): Questa scelta definisce se includere nell'analisi l'intero set di stimoli visivi (*All\_Pictures*) usato nell'esperimento originale, oppure escludere sistematicamente le immagini nuove (*No\_Novel\_Pictures*), ovvero mantenendo solo i trial in cui le immagini provengono dal database MultiPic. Questa decisione permette di verificare la robustezza delle analisi rispetto alle frequenze lessicali dei nomi per la categoria di base, che risultano più basse per la maggior parte delle nuove immagini introdotte rispetto alle immagini provenienti da MultiPic.
2. **Trattamento e filtraggio degli errori linguistici** (2 diramazioni): La scelta determina il livello di severità nella pulizia delle risposte verbali errate. L'opzione restrittiva (*Strict\_Errors\_Only*) mantiene solo i trial privi di errore o in cui vengono forniti dei sinonimi, cioè casi in cui il partecipante fornisce come risposta il nome di base o la categoria associati all'immagine o un loro sinonimo; l'opzione più inclusiva (*Broad\_Errors\_Included*) invece mantiene nel dataset anche tipologie di errore più ampie e sfumate come gli errori di specificità o semantici, che però permettono comunque di identificare a che livello concettuale (base o categoria) appartiene la risposta del partecipante.

3. **Verifica di robustezza sulle categorie lessicali (Leave-One-Out)** (6 diramazioni): Questa decisione prevede la stima dei modelli sia sull'intero set semantico (*None*), sia escludendo sistematicamente una alla volta le cinque categorie lessicali più polarizzanti del disegno sperimentale originale (*instruments de musique, fruits, professions, nature, accessoires*), in particolare le due con maggior proporzione di risposte di livello *Category* e le tre con la minor proporzione di risposte per *Category*. Questo con l'obiettivo di verificare se l'effetto di allineamento sia universale o trainato da specifiche eccezioni lessicali. Si è scelto di non fare questa verifica per tutte e 15 le categorie in quanto avrebbe portato a un numero estremamente elevato di rami del multiverso, e ci aspettiamo che se c'è qualche categoria che è trainante dei risultati in un senso o in un altro si trovi in corrispondenza delle code della distribuzione.
4. **Tipo di modello** (4 diramazioni): Si propongono 4 diverse strategie di modellazione, e cioè nello specifico si confrontano modelli lineari classici sui dati grezzi (*Linear*), modelli lineari con trasformazione logaritmica della risposta (*Log-Linear*), modelli lineari generalizzati con famiglia Inverse-Gaussian e legame logaritmico (*InvGauss-Log*), e modelli con famiglia Gamma e funzione di legame identità (*Gamma-Identity*). L'obiettivo di questo step è quello di confrontare diverse strategie con cui può essere modellata la tipica asimmetria e non-normalità dei tempi di reazione.
5. **Definizione del raggruppamento per gli effetti casuali degli item** (2 diramazioni): Nella struttura a effetti misti del modello, questa scelta stabilisce l'unità di raggruppamento per controllare la variabilità casuale legata agli stimoli. In particolare si varia la specificazione inserendo l'effetto casuale associato al singolo oggetto specifico (*Item*) oppure l'effetto casuale legato alla categoria semantica più ampia di appartenenza (*Category*).
6. **Inclusione o meno delle pendenze casuali (Random Slopes) entro-soggetto** (2 diramazioni): Si confrontano modelli standard che prevedono solo le intercettazioni casuali per soggetti e item o category (*RandomSlope\_No*) con modelli che includono anche la pendenza casuale per la variabile di disegno sperimentale condition (*RandomSlope\_Sì*).

Ciascuna combinazione di queste scelte metodologiche definisce quindi un ramo specifico del nostro multiverso, così da generare un'architettura complessiva del multiverso di  $2 \times 2 \times 6 \times 4 \times 2 \times 2 = 384$  rami analitici. I risultati ottenuti per ogni singola combinazione della griglia costituiscono la base per la costruzione delle specification curve e dei volcano plot, che permettono di valutare la robustezza delle conclusioni.



## 3 Risultati

### 3.1 Specification curve

Al fine di esaminare la robustezza dei tre effetti di interesse (`ORDER`, `ALIGNMENT:CONDITION` e `ORDER:ALIGNMENT`) stimati nell’ambito di un multiverso di scelte analitiche, è stato utilizzato il pacchetto R `specr` [4] per la costruzione di curve di specificazione (specification curves) dei risultati ottenuti nelle diverse specificazioni del multiverso. Tale rappresentazione grafica consente infatti l’identificazione di risultati statisticamente plausibili. Poiché il multiverso include tipologie di modelli statistici differenti, i cui coefficienti non sono direttamente confrontabili tra loro, le curve di specificazione sono state suddivise in due gruppi distinti, ciascuno relativo a una famiglia di modelli comparabili sulla stessa scala. In particolare, da un lato sono rappresentati i modelli lineari semplici (Linear) e lineari generalizzati con famiglia Gamma e funzione di legame identità (Gamma-Identity); dall’altro i modelli lineari con trasformazione logaritmica della risposta (Log-Linear) e lineari generalizzati con famiglia Inverse-Gaussian e legame logaritmico (InvGauss-Log).

La Figura 1 riporta le specification curve relative al parametro stimato dell’effetto di `ORDER` nei 384 modelli considerati. Come evidenziato in rosso, tutte le stime risultano significativamente negative, indicando una progressiva riduzione dei tempi di reazione all’aumentare del numero di trial. Sebbene l’entità dell’effetto sia contenuta, questo risultato suggerisce la presenza di un processo di familiarizzazione con il compito nel corso dello studio, accompagnato da un graduale miglioramento della prestazione dei partecipanti. In particolare, nei due modelli con risposta sulla scala originale (Linear e Gamma-Identity) il parametro stimato è compreso tra -1 e -2, suggerendo una riduzione media dei tempi di reazione dell’ordine di 1 o 2 millisecondi per ogni incremento di trial.

In Figura 2, invece, sono riportate le specification curve relative ai parametri dell’interazione `ALIGNMENT:CONDITION`. Come evidenziato in blu, tutti i coefficienti assumono valori significativamente positivi, suggerendo che l’allineamento alla categoria sovraordinata (es. dire “frutto” anziché “mela”) sia associato a un incremento dei tempi di risposta. Questo risultato supporta l’interpretazione secondo cui il fenomeno rifletta un processo di allineamento strategico e deliberato, piuttosto che automatico, caratterizzato da un maggiore carico cognitivo. Dai grafici è percepibile una differenza marcata tra le stime dei parametri ottenute dai modelli caratterizzati da diverse strutture degli effetti casuali. In particolare, la scelta del criterio di raggruppamento (basato sul singolo item oppure sulla categoria semantica di appartenenza) influisce sui risultati che, pur mantenendo sempre significatività statistica, risultano più pronunciati nel caso del raggruppamento “Category”. Tale evidenza è riconducibile al fatto che la modifica della struttura della varianza degli effetti casuali comporta una modifica della stima degli effetti fissi.

### Beta Curve (Scala MS e Scala Trasformata): Effetto Principale ORDER




Figura 1: Specification curve per l'effetto marginale di ORDER.

### Beta Curve (Scala MS e Scala Trasformata): Interazione ALIGNMENT:CONDITION




Figura 2: Specification curve per l'effetto marginale di ALIGNMENT:CONDITION.

### Beta Curve (Scala MS e Scala Trasformata): Interazione ORDER:ALIGNMENT




Figura 3: Specification curve per l'effetto marginale di ORDER:ALIGNMENT.

La Figura 3 mostra le specification curve dei parametri dell’interazione `ORDER:ALIGNMENT`. A differenza degli altri due effetti, tale interazione non risulta statisticamente significativa nella maggioranza dei modelli valutati nell’ambito della multiverse analysis. Solo 11 modelli, evidenziati in blu, mostrano infatti una significatività marginale positiva  $\alpha$  pari a 0.05. Questo risultato suggerisce che il livello di sforzo cognitivo (strategico) o di facilitazione (automatica) dei partecipanti nell’allineamento con il robot varia con il procedere dell’esperimento, ma non è attribuibile al tipo di risposta fornita dal robot.

L’analisi grafica delle curve di specificazione, in particolare di quelle relative all’interazione `ORDER:ALIGNMENT`, ha inoltre consentito di identificare alcuni valori particolarmente influenti associati a una delle quindici categorie lessicali considerate, ossia strumenti musicali. Nei rami del multiverso in cui tale categoria viene esclusa, infatti, le stime dei parametri assumono valori più estremi, conducendo a risultati caratterizzati da una maggiore evidenza statistica e, di conseguenza, a conclusioni più marcate in termini di significatività.

Questo andamento è particolarmente evidente nelle curve di specificazione dell’effetto di `ORDER`, dove l’esclusione della categoria strumenti musicali produce stime più piccole e quindi più significative. Un effetto analogo, e ancora più marcato, si osserva nelle curve relative all’interazione `ORDER:ALIGNMENT`, in cui l’esclusione della stessa categoria non solo ne aumenta il valore delle stime, ma porta anche alla comparsa di alcuni risultati significativi, seppur di entità ridotta.

Tale risultato rimarca la possibilità che le osservazioni riguardanti *strumenti musicali* siano particolarmente rumorose: l’ipotesi che tale differenza alla loro esclusione possa essere dovuta a fenomeni come la ridotta frequenza lessicale degli strumenti raffigurati è plausibile ma non sufficiente, in quanto altrimenti lo stesso fenomeno dovrebbe essere osservato anche per i *frutti*, i quali assumono frequenze lessicali simili. Si osserva però dall’analisi descrittiva di Gastaldon & Calignano che, prese soltanto le immagini *Novel*, il partecipante rispondeva con la categoria nel 58% dei trial sotto condizione *basic* e nel 72% dei trial sotto condizione *condition*, una proporzione estremamente elevata ed inusuale rispetto alle altre categorie, sia per *MultiPic* che per *Novel*. Si può quindi ipotizzare che gli *strumenti musicali* aggiunti con *Novel* evidenzino un fenomeno non generalizzabile e che perciò la loro inclusione nel modello provocherebbe l’adattamento di rumore.

## 3.2 Volcano plot

Oltre alle specification curve può essere utile osservare i volcano plot; infatti, mentre le specification curve mostrano informazioni soprattutto legate ai valori stimati dei coefficienti, i volcano plot mostrano principalmente come varia il p-value rispetto alle stime dei coefficienti, a seconda delle scelte di preprocessing (n.b.: sull’asse  $y$  compare una trasformazione del p-value, ovvero  $-\log_{10}(\text{p-value})$ ).

Si è scelto di separare i grafici per le due scale della risposta come per le specification curve, quindi per ognuno dei 3 effetti considerati sono affiancati i due grafici per le due




Figura 4: Volcano plot per l'effetto marginale di ORDER.

scale. Si è scelto inoltre di evidenziare tramite colori la categoria rimossa delle immagini a cui il valore fa riferimento.

In Figura 4 si possono osservare i volcano plot per il coefficiente dell'effetto marginale di ORDER. Come già osservato tutti i coefficienti risultano essere significativi, quindi si conferma la riduzione significativa del tempo di risposta col procedere dei trial, notando che non sembrano esserci grosse differenze al variare della categoria rimossa.

In Figura 5 sono presenti i volcano plot per l'effetto di ALIGNMENT:CONDITION. Anche in questo caso si conferma la generale significatività dell'effetto, come già osservato attraverso le specification curve. Anche se da questi grafici non emerge, i due gruppi separati di punti sono legati ai due tipi di effetti casuali (per singolo item o per categoria), che è l'unica scelta di analisi che porta a differenze osservabili dei risultati.

In Figura 6 si possono osservare infine i volcano plot per l'effetto di interazione di ORDER:ALIGNMENT. In questo caso, come già emerso in precedenza, si osserva come in generale non sia presente un effetto significativo, ovvero sembra che non ci siano prove sufficienti per mostrare che esista una differenza significativa rispetto al tempo di reazione tra il caso di allineamento e il non-allineamento al procedere dei trial. Le uniche eccezioni, caratterizzate dalla presenza di effetti significativi, sono legate alla rimozione degli strumenti musicali nel modello con risposta sulla scala originale, come già discusso in precedenza.




Figura 5: Volcano plot per l'effetto di ALIGNMENT:CONDITION.




Figura 6: Volcano plot per l'effetto di ORDER:ALIGNMENT.

## 4 Conclusioni e note metodologiche

In conclusione, la nostra analisi di multiverse conferma l'ipotesi per cui l'effetto di allineamento osservato è dovuto a uno sforzo strategico, rispetto a quella di un allineamento automatico. Il rallentamento sistematico dei tempi di reazione nell'interazione **ALIGNMENT:CONDITION**, costante in tutti i 384 modelli, dimostra che allinearsi alla categoria sovraordinata richiede un maggiore carico cognitivo ed è il frutto di una strategia deliberata, non di un processo inconscio. E a supporto di ciò, la generale non-significatività dell'interazione **ORDER:ALIGNMENT** indica che questo carico cognitivo resta stabile nel tempo: il divario tra risposte allineate e non allineate non si riduce con il procedere dei trial, indicando che non c'è un effetto di facilitazione nel caso di allineamento (**ALIGNMENT:CONDITION**), ma solo un miglioramento generalizzato (**ORDER**)

Oltre alla verifica delle ipotesi principali, la rianalisi dei dati ha fatto emergere alcune criticità metodologiche che meritano di essere discusse.

Abbiamo riscontrato particolari criticità nella gestione della variabile **BLOCK\_4** definita da Cirillo et al., a causa dell'arbitrarietà — non giustificata dagli autori — con cui le osservazioni sono state suddivise in quattro blocchi, peraltro di dimensioni disuguali. L'esperimento, per come viene descritto, prevede che i partecipanti vedano 90 immagini per sessione (nominandone 45 e lasciando le restanti 45 al robot in modo alternato) seguite da una pausa, ripetendo questo ciclo per 5 volte fino al completamento dei 450 stimoli totali. Di conseguenza, per quanto la scelta di modellare la progressione temporale attraverso una variabile categoriale possa avere una sua legittimità teorica, la divisione operata nel dataset originale crea evidenti problemi metodologici in quanto la categorizzazione dei blocchi non rispetta la reale struttura del disegno sperimentale.

La figura 7 mostra una forte differenza nei tassi di allineamento tra le diverse condizioni. Mentre per la condizione Basic si può notare una forte proporzione di allineamento indipendente dalla categoria lessicale, per la condizione Category la proporzione di risposte allineate è molto più bassa e sembra poter essere correlata con la categoria lessicale. Questo andamento solleva dei dubbi sui criteri di selezione delle immagini e sulla composizione interna dei domini semantici nel disegno sperimentale originale, evidenziando un potenziale bias sistematico legato a questa scelta. Al fine di verificare meglio la reale robustezza delle conclusioni sarebbe quindi opportuno rifare le analisi utilizzando un dataset strutturalmente diverso e bilanciato, cosa che però non è stata possibile nell'ambito del nostro attuale lavoro.






Figura 7: Proporzione di risposte Aligned per Category a seconda di Condition

Per ottenere un'ulteriore indicazione sulla robustezza dei risultati avremmo voluto applicare la Post-Inference Multiverse Analysis (PIMA). Tuttavia, questo passaggio non è stato possibile poiché l'omonimo pacchetto richiede come input l'intera struttura degli oggetti modello e non supporta la specificazione degli effetti casuali. Nonostante questo limite tecnico, l'analisi visiva delle curve di specificazione e dei volcano plot indica comunque che le conclusioni tratte siano robuste rispetto alle diverse scelte analitiche adottate.

Infine, per garantire la massima trasparenza, la riproducibilità dei risultati e la tracciabilità di ogni singolo passaggio di questa analisi, l'intero flusso di lavoro — inclusi gli script di preprocessing, il codice R di modellazione del multiverso e i grafici generati — è stato organizzato e reso interamente disponibile all'interno di una repository Github dedicata ([lorispivato/progetto-specification-curve](#)).

## Riferimenti bibliografici

- [1] Giusy Cirillo, Elin Runnqvist, Kristof Strijkers, Noël Nguyen, and Cristina Baus. Conceptual alignment in a joint picture-naming task performed with a social robot. *Cognition*, 227:105213, 2022.
- [2] Jon Andoni Duñabeitia, Davide Crepaldi, Antje S. Meyer, Boris New, Christos Pliatsikas, Eva Smolka, and Marc Brysbaert. Multipic: A standardized set of 750 drawings with norms for six european languages. *The Quarterly Journal of Experimental Psychology*, 71(4):808–816, 2018.
- [3] Simone Gastaldon and Giulia Calignano. Linguistic alignment with an artificial agent: A commentary and re-analysis. *Cognition*, 259:106099, 2025.
- [4] Philipp K. Masur and Michael Scharkow. `specr`: Conducting and visualizing specification curve analyses (version 1.0.0), 2020.